

## Cursul 5

### II) Sisteme de ecuații liniare supradeterminate. Regresii


- Vrem să rezolvăm numeric sisteme de ecuații liniare supradeterminate, i.e.

$$A \cdot x = b, (1)$$

$$\text{unde } \begin{cases} A \in \mathcal{M}_{m,n}(\mathbb{R}), m > n, \text{rang}(A) = n \\ b \in \mathbb{R}^m \end{cases}$$

- Exemplu: Regresia liniară

Vrem să determinăm dreapta  $y = \alpha \cdot x + \beta$  cea mai „apropiată” de punctele  $\{(x_i, y_i)\}_{i=0,1,2}$



$$\begin{cases} \alpha \cdot x_0 + \beta = y_0 \\ \alpha \cdot x_1 + \beta = y_1 \\ \alpha \cdot x_2 + \beta = y_2 \end{cases}$$

$$(\Rightarrow) \underbrace{\begin{bmatrix} x_0 & 1 \\ x_1 & 1 \\ x_2 & 1 \end{bmatrix}}_A \cdot \underbrace{\begin{bmatrix} \alpha \\ \beta \end{bmatrix}}_x = \underbrace{\begin{bmatrix} y_0 \\ y_1 \\ y_2 \end{bmatrix}}_b$$

- Teorema Kronecker-Capelli ne spune că avem o soluție  $(\Rightarrow) \text{rang}(A) = \text{rang}(A|b)$
- Cum  $\text{rang}(A) = 2 \Rightarrow$  sistemul are soluție  $(\Rightarrow) \text{rang}(A|b) = ?$

$$(\Rightarrow) \begin{vmatrix} x_0 & 1 & y_0 \\ x_1 & 1 & y_1 \\ x_2 & 1 & y_2 \end{vmatrix} = 0 \Leftrightarrow (x_i, y_i)_{i=\overline{0,2}} \text{ sunt coliniare.}$$

Q: Ce ne facem când punctele nu sunt coliniare?

Vom construi o dreaptă astfel încât aceasta să fie cât mai apropiată de punctele  $(x_i, y_i)_{i=\overline{0,2}}$

- Mai exact, caut  $\alpha, \beta \in \mathbb{R}$  a. i.

$$\sum_{i=0}^2 (\alpha X_i + \beta - Y_i)^2 \text{ să fie minim}$$

- Observație

$$\begin{aligned} \|A\mathbf{x} - \mathbf{b}\|_2^2 &= \left\| \begin{pmatrix} x_0 & 1 \\ x_1 & 1 \\ x_2 & 1 \end{pmatrix} \cdot \begin{pmatrix} \alpha \\ \beta \end{pmatrix} - \begin{pmatrix} Y_0 \\ Y_1 \\ Y_2 \end{pmatrix} \right\|_2^2 \\ &= \left\| \begin{pmatrix} \alpha x_0 + \beta - Y_0 \\ \alpha x_1 + \beta - Y_1 \\ \alpha x_2 + \beta - Y_2 \end{pmatrix} \right\|_2^2 = \sum_{i=0}^2 (\alpha x_i + \beta - Y_i)^2 \end{aligned}$$

- Definiție

i) Numim problema celor mai mici pătrate (PCMP) următoarea problemă

$$\hat{\mathbf{x}} := \operatorname{argmin}_{\mathbf{x} \in \mathbb{R}^n} \|A\mathbf{x} - \mathbf{b}\|_2^2 \quad (2)$$

$$\Leftrightarrow \|A\hat{\mathbf{x}} - \mathbf{b}\|_2^2 \leq \|A\mathbf{x} - \mathbf{b}\|_2^2, \quad \forall \mathbf{x} \in \mathbb{R}^n$$

ii) Dacă  $\exists \hat{\mathbf{x}} \in \mathbb{R}^n$  soluție pentru (2), aceasta se numește soluția PCMP a sistemului supradeterminat de ecuații liniare (1).

- În continuare, vom răspunde la următoarele întrebări:

$Q_1$ : Există o soluție a PCMP?

$Q_2$ : Dacă da, este unică?

$Q_3$ : Algoritmi de determinare a soluției?

- Teoremă

Considerăm sistemul supradeterminat (1)

Dacă  $A$  este inversabilă la stânga,

i.e.  $\exists A^{-1} \in \mathcal{M}_{m,m}(\mathbb{R})$  a.î.  $A^{-1}A = I_m$ , atunci

PCMP (2) are o unică soluție dată de rezolvarea sistemului de ecuații normale asociat

$$A^T A \hat{x} = A^T b \quad (3)$$

Demonstrație:

Pasul I: Arăt că  $A^T A \in \mathcal{M}_n(\mathbb{R})$  este simetrică și pozitiv definită (SPD)

Cum  $(A^T A)^T = A^T A$ ,  $A^T A$  este simetrică

Presupunem prin absurd că  $A^T A$  nu este pozitiv definită  $\Rightarrow \exists x \in \mathbb{R}^m \setminus \{0\}$  a.î.

$$x^T (A^T A) x = 0 \Leftrightarrow (x^T A^T) (A x) = 0 \Leftrightarrow$$

$$(A x)^T (A x) = 0 \Leftrightarrow \|A x\|_2^2 = 0 \Leftrightarrow$$

$$A x = 0 \in \mathbb{R}^m$$

Înmulțim la stânga cu  $A^{-1} \in \mathcal{M}_{m,m}(\mathbb{R})$ :

$$A^{-1} A x = 0 \in \mathbb{R}^m \Leftrightarrow x = 0 \text{ } \times$$

$\Rightarrow A^T A$  este o matrice SPD

Pasul II: Arătați că soluția  $\hat{x} \in \mathbb{R}^m$  a sistemului  $A^T A x = A^T b$  este și unica soluție PCMP, i.e.

$$\|A \hat{x} - b\|_2^2 < \|A x - b\|_2^2 \quad \forall x \neq \hat{x}$$

Fie  $x \in \mathbb{R}^m$  a.î.  $x \neq \hat{x}$ .

$$\|A x - b\|_2^2 = \|(A x - A \hat{x}) + (A \hat{x} - b)\|_2^2$$

$$= [A(x - \hat{x}) + (A \hat{x} - b)]^T \cdot [A(x - \hat{x}) + (A \hat{x} - b)]$$

$$= \|A(x - \hat{x})\|_2^2 + 2[A(x - \hat{x})]^T (A\hat{x} - b) + \|A\hat{x} - b\|_2^2$$

Observăm că :

$$i) \|A(x - \hat{x})\|_2^2 = (x - \hat{x})^T A^T A (x - \hat{x}) > 0$$

deoarece  $A^T A$  este pozitiv definită

$$ii) [A(x - \hat{x})]^T (A\hat{x} - b) =$$

$$= (x - \hat{x})^T A^T (A\hat{x} - b)$$

$$= (x - \hat{x})^T \underbrace{(A^T A \hat{x} - A^T b)}_{0 \in \mathbb{R}^n} = 0$$

Din i) și ii) obținem că

$$\|Ax - b\|_2^2 > \|A\hat{x} - b\|_2^2 \quad \forall x \neq \hat{x} \quad \square$$

• Observație :

Cum  $A^T A \in \mathcal{M}_n(\mathbb{R})$  este simetrică și

pozitiv definită, putem aplica factorizarea

Cholesky pentru a rezolva sistemul

$$A^T A x = A^T b$$

și a obține soluția PCMP a  $Ax = b$ .

• Aplicație: Dreapta de regresie

Coefficienții dreptei de regresie,  $\hat{x} = \begin{bmatrix} \alpha \\ \beta \end{bmatrix}$ ,

cei mai apropiată de punctele  $(x_i, y_i)_{i=0, m-1}$

se determină rezolvând sistemul

$$A^T A \hat{x} = A^T b$$

$$\Leftrightarrow \begin{bmatrix} x_0 & x_1 & \dots & x_{m-1} \\ 1 & 1 & \dots & 1 \end{bmatrix} \cdot \begin{bmatrix} x_0 & 1 \\ \vdots & \vdots \\ x_{m-1} & 1 \end{bmatrix} \cdot \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} x_0 & \dots & x_{m-1} \\ 1 & \dots & 1 \end{bmatrix} \cdot \begin{bmatrix} y_0 \\ \vdots \\ y_{m-1} \end{bmatrix}$$

$$\Leftrightarrow \begin{bmatrix} \sum_{i=0}^{m-1} x_i^2 & \sum_{i=0}^{m-1} x_i \\ \sum_{i=0}^{m-1} x_i & m \end{bmatrix} \cdot \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \sum_{i=0}^{m-1} x_i y_i \\ \sum_{i=0}^{m-1} y_i \end{bmatrix}$$